

Università della Calabria

Dipartimento di Ingegneria Informatica, Modellistica,
Elettronica e Sistemistica

Corso di Laurea Magistrale in Ingegneria Informatica
Indirizzo Intelligenza Artificiale

RADON-NL

Anomaly Detection Non Supervisionata tramite Negative Learning Feature-Aware e Stabilizzazione Dinamica

Report di Machine Learning e Deep Learning

Studente:
Giuseppe Cuiuri
Matr. 269480

Anno Accademico 2025/2026
Febbraio 2026

Indice

1 Introduzione **3**

2 Background e Stato dell'Arte **5**
2.1 Approcci Representation-based: La famiglia Deep SVDD 5
2.2 Approcci Reconstruction-based: Autoencoder 6
2.2.1 L'Autoencoder come Anomaly Detector 6
2.3 Limiti degli approcci AE-based 7
2.3.1 Over-generalization 7
2.3.2 Contaminazione del Training Set 7
2.4 Stato dell'Arte: Robustezza e Negative Learning 8
2.4.1 Robustezza tramite Selezione Dinamica: RADON 8
2.4.2 Migliorare la separabilità: Negative Learning e AE-SAD 8
2.5 Posizionamento del Lavoro 8

3 Dataset e Analisi Esplorativa **11**
3.1 NSL-KDD: Network Intrusion Detection 11
3.1.1 Preprocessing e Feature Engineering 11
3.1.2 Analisi della Distribuzione e Contaminazione 12
3.2 MNIST: Rilevazione di Anomalie su Immagini 13
3.2.1 Setup Sperimentale 13
3.2.2 Strategia di Contaminazione 13
3.3 Sintesi delle Indagini 13

4 Metodologia Proposta: RADON con Negative Learning **15**
4.1 Framework di base: RADON 15
4.1.1 Setup e Similarità di Ricostruzione 16
4.1.2 Funzione Obiettivo Base (Fase Warmup) 17
4.1.3 Proiezione Dinamica e Thresholding 18
4.2 Feature-Aware Negative Learning 18
4.2.1 Trasformazione Feature-Aware $F(\mathbf{x})$ 18
4.2.2 Loss di Negative Learning 19
4.2.3 Funzione Obiettivo Totale 19
4.3 Strategie di Stabilizzazione del Training 19
4.3.1 Pseudo-Etichette e Early Divergence 20
4.3.2 Protocollo di Warm-up 20
4.3.3 Scheduling Temporale (Ramp-up) 20
4.3.4 Adattamento alla Cardinalità (λ-Scaling) 21
4.3.5 Curriculum Learning (Filtro Quantile) 21
4.3.6 Confidence Weighting 22
4.3.7 Consistency Loss Pesata 22
4.4 Strategia di Early Stopping Projection-Aware 22
4.5 Algoritmo Complessivo 23

5 Valutazione Sperimentale: Ablation Study e Comparazione con lo Stato dell'Arte 24
5.1 Setup Sperimentale e Strategia di Ablation 25
5.2 Risultati su NSL-KDD: L'impatto delle contaminazioni 26
5.2.1 Low Contamination (1%) 26
5.2.2 Standard Contamination (5%) 27
5.2.3 High Contamination (10%) 27
5.3 Explainability (XAI) su NSL-KDD: Attribuzione causale e firma del Negative Learning 27
5.3.1 Attribuzione per feature categoriche: group ablation verso la modalità dei normali 27
5.3.2 Attribuzione causale per feature numeriche: clip-to-normal (counterfactual) . 28
5.3.3 Diagnostica della "firma" del Negative Learning 28
5.4 Risultati su MNIST: Geometria e Stabilità 30
5.4.1 Easy Group: Geometria Distinta 31
5.4.2 Hard Group: Ambiguità Morfologica 31
5.4.3 Analisi XAI: Interpretabilità delle Ricostruzioni 31
5.5 Il ruolo delle componenti 32

A Tabella completa Ablation NSLKDD 33

Chapter 1

Introduzione

Negli ultimi anni, il problema dell'*Anomaly Detection* (AD) ha assunto un ruolo centrale in numerosi ambiti applicativi, tra cui la sicurezza informatica, il monitoraggio di sistemi industriali, l'Internet of Things (IoT), la rilevazione di frodi finanziarie e l'analisi di dati biomedicali. In questi contesti, l'obiettivo principale consiste nell'identificare automaticamente comportamenti, eventi o osservazioni che si discostano in modo significativo dal comportamento considerato normale.
Una caratteristica comune di molti scenari reali è la forte asimmetria nella disponibilità delle etichette: mentre i dati normali sono abbondanti e facilmente osservabili, le anomalie risultano rare, eterogenee e spesso non etichettate. Questa condizione rende i metodi di anomaly detection supervisionati poco praticabili, favorendo l'adozione di approcci *non supervisionati* o *semi-supervisionati*, nei quali il modello viene addestrato prevalentemente (o esclusivamente) su dati normali.
Tra le tecniche più utilizzate in questo ambito, gli *Autoencoder* (AE) hanno dimostrato una notevole efficacia grazie alla loro capacità di apprendere rappresentazioni compatte dei dati e di ricostruire accuratamente le osservazioni appartenenti alla distribuzione normale. L'ipotesi di base è che un modello addestrato su dati normali presenti un errore di ricostruzione significativamente più elevato sugli outlier, consentendo così di utilizzare tale errore come *anomaly score*. Tuttavia, è noto che gli autoencoder profondi soffrono spesso di fenomeni di *over-generalization*, riuscendo a ricostruire adeguatamente anche osservazioni anomale, specialmente in presenza di dati complessi o ad alta dimensionalità.
Un'ulteriore difficoltà pratica è rappresentata dalla *contaminazione del training set*: nei contesti non supervisionati, è frequente che il dataset utilizzato per l'addestramento contenga una frazione ignota di anomalie. In tali condizioni, un addestramento diretto sull'intero dataset può portare il modello ad apprendere anche le caratteristiche degli outlier, degradando le prestazioni di rilevazione.
Per affrontare queste problematiche, recenti lavori hanno proposto strategie basate su una selezione dinamica dei dati di training e su funzioni di loss progettate per penalizzare esplicitamente la ricostruzione delle anomalie. In questa direzione si collocano, da un lato, il metodo RADON (*Robust Autoencoder for Unsupervised Anomaly Detection*), che introduce una partizione iterativa del dataset in campioni affidabilmente normali e campioni sospetti, e dall'altro il paradigma del *Negative Learning*, formalizzato nel metodo AE-SAD, che forza il modello a ricostruire le anomalie verso un target negativo anziché verso l'input originale.
Il presente lavoro si inserisce in questo filone di ricerca con l'obiettivo di analizzare, implementare

ed estendere il metodo RADON, integrando al suo interno la logica di Negative Learning proposta in AE-SAD. Una sfida specifica affrontata in questa tesi riguarda l'adattamento di tale paradigma a dati tabulari eterogenei, dove l'applicazione ingenua del target negativo può compromettere la semantica delle feature categoriche. In particolare, viene studiata una procedura di addestramento ibrida e "feature-aware" che combina la selezione dinamica degli inlier di RADON con una funzione di loss negativa applicata agli outlier pseudo-etichettati, al fine di migliorare la separabilità tra dati normali e anomali. L'approccio viene valutato sia su dataset di tipo image-based (MNIST), sia su dataset tabulari reali per la network intrusion detection (NSL-KDD), evidenziandone punti di forza, limiti e implicazioni pratiche.

Chapter 2

Background e Stato dell'Arte

L'*Anomaly Detection* (AD) è il processo di identificazione di osservazioni che si discostano significativamente dal comportamento normale dei dati. Come evidenziato nella survey di Chalapathy et al. [2], l'avvento del Deep Learning ha rivoluzionato questo campo, permettendo di gestire dati ad alta dimensionalità (immagini, serie temporali) dove i metodi classici basati su distanza (k-NN) o densità (LOF) falliscono a causa della *curse of dimensionality*.

In letteratura, i metodi di Deep AD possono essere suddivisi in due macro-famiglie principali:

1. **Modelli Representation-based (One-Class):** apprendono uno spazio latente compatto in cui gli inliers sono vicini tra loro (es. Deep SVDD).
2. **Modelli Reconstruction-based:** apprendono a ricostruire i dati normali, assumendo che le anomalie generino un errore di ricostruzione elevato (es. Autoencoder).

2.1 Approcci Representation-based: La famiglia Deep SVDD

Questa famiglia di metodi mira a incapsulare i dati normali all'interno di una sfera (o altra forma geometrica) nello spazio delle feature.

Il capostipite è **Deep SVDD** (Support Vector Data Description) [5], che allena una rete neurale per mappare i dati di input in uno spazio latente minimizzando la distanza da un centro c predeterminato. L'obiettivo è minimizzare il volume della sfera che racchiude i dati normali:

$$\min_{\mathcal{W}} \frac{1}{n} \sum_{i=1}^{n} \|\phi(x_i; \mathcal{W}) - c\|^2 + \frac{\lambda}{2} \|\mathcal{W}\|_F^2$$

Le anomalie, non rispettando i pattern comuni, verranno mappate lontane dal centro c, come illustrato in Figura 2.1.

Successivamente, **Deep SAD** [4] ha esteso questo concetto al paradigma *semi-supervisionato*. Se sono disponibili poche etichette di anomalie durante il training, Deep SAD modifica la funzione obiettivo per:

- Minimizzare la distanza dal centro per i campioni etichettati come normali;
- Massimizzare la distanza dal centro per i campioni etichettati come anomali.

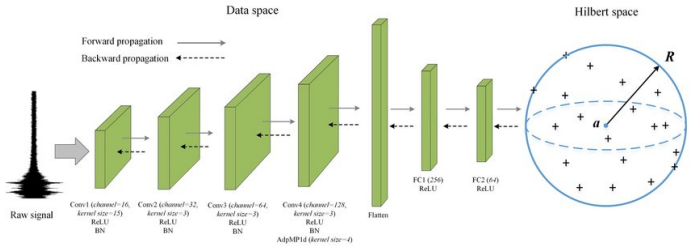


Figure 2.1: Rappresentazione concettuale di Deep SVDD: i dati normali sono mappati all'interno di una ipersfera di raggio minimo.

Sebbene efficaci, questi metodi operano esclusivamente nello spazio latente e non forniscono una ricostruzione del dato, che è invece fondamentale per l'approccio proposto in questa tesi (basato su RADON e Negative Learning).

2.2 Approcci Reconstruction-based: Autoencoder

A differenza dei metodi One-Class, gli approcci basati sulla ricostruzione utilizzano **Autoencoder** (AE) o varianti generative. Questa tesi si concentra su questa famiglia poiché permette di definire l'anomalia in termini di errore residuo nello spazio originale.

Un **Autoencoder** (AE) è una rete neurale progettata per apprendere in modo non supervisionato una rappresentazione compressa (encoding) dei dati di input. L'architettura è composta da due moduli principali:

- **Encoder** $\psi(\cdot)$: mappa l'input $\mathbf{x} \in \mathbb{R}^d$ in uno spazio latente $\mathbf{z} \in \mathbb{R}^k$ con $k < d$;
- **Decoder** $\varphi(\cdot)$: ricostruisce l'approssimazione $\hat{\mathbf{x}}$ a partire dal codice latente $\mathbf{z}$.

Formalmente:

$$\mathbf{z} = \psi(\mathbf{x}), \qquad \hat{\mathbf{x}} = \varphi(\mathbf{z}) = \varphi(\psi(\mathbf{x})).$$

L'addestramento avviene minimizzando una **loss di ricostruzione**, che quantifica la discrepanza tra l'input originale e l'output generato. La scelta della loss dipende dalla natura dei dati; le più comuni sono l'errore quadratico medio (MSE) e la similarità coseno.

2.2.1 L'Autoencoder come Anomaly Detector

Nel contesto dell'AD, si assume che l'Autoencoder venga addestrato prevalentemente su dati normali (inliers). L'ipotesi sottostante è che la rete apprenda a comprimere e ricostruire efficacemente i pattern frequenti della normalità, ma fallisca nel ricostruire pattern anomali mai visti o rari.

Si definisce quindi un **anomaly score** $s(\mathbf{x})$ basato sull'errore di ricostruzione. Se si utilizza la norma L_2:

$$s(\mathbf{x}) = \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2.$$

In alternativa, per ottenere una metrica invariante alla scala (utile in metodi come RADON), si utilizza la **cosine similarity**:

$$\cos(\mathbf{x}, \hat{\mathbf{x}}) = \frac{\mathbf{x}^\top \hat{\mathbf{x}}}{\|\mathbf{x}\|_2 \|\hat{\mathbf{x}}\|_2}, \qquad s(\mathbf{x}) = 1 - \cos(\mathbf{x}, \hat{\mathbf{x}}).$$

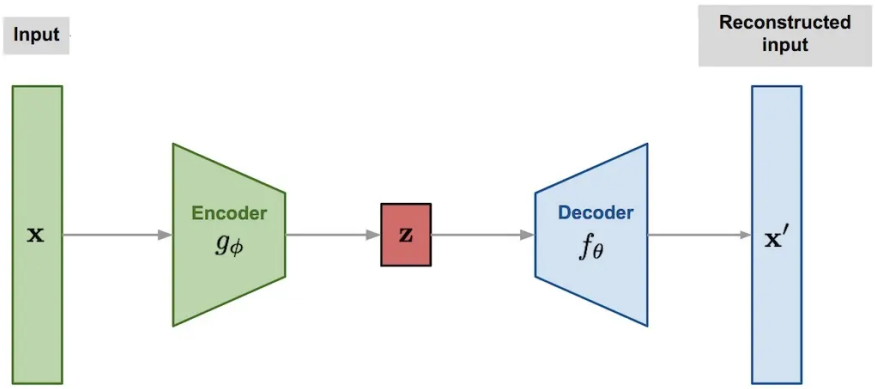


Figure 2.2: Architettura standard di un Autoencoder: l'input viene compresso nello spazio latente z e successivamente ricostruito.

In questo scenario, un valore di $s(\mathbf{x})$ elevato indica una bassa similarità tra input e output, segnalando una potenziale anomalia.

2.3 Limiti degli approcci AE-based

Nonostante la loro popolarità, gli Autoencoder standard soffrono di due criticità principali che ne limitano l'efficacia in scenari reali e non supervisionati.

2.3.1 Over-generalization

Gli autoencoder profondi possiedono una capacità rappresentativa molto elevata. È noto che, se la rete è sufficientemente complessa, essa rischia di "imparare a copiare" l'input piuttosto che apprendere le feature significative della normalità. Questo porta al fenomeno dell'*over-generalization*: il modello ricostruisce bene anche le anomalie, riducendo il gap di errore tra inliers e outliers e rendendo inefficace l'anomaly score.

2.3.2 Contaminazione del Training Set

In contesti puramente non supervisionati, è raro disporre di un training set composto esclusivamente da dati normali. Spesso i dati contengono una frazione ignota di anomalie (*contaminazione*). Un addestramento standard su dati contaminati porta il modello a incorporare le caratteristiche degli outlier nella sua rappresentazione della "normalità", degradando drasticamente le prestazioni di rilevazione.

2.4 Stato dell'Arte: Robustezza e Negative Learning

Per superare i limiti sopra descritti, la letteratura recente si è mossa verso due direzioni principali: strategie di selezione dinamica dei dati (per gestire la contaminazione) e nuove funzioni obiettivo per forzare la separabilità (per gestire l'over-generalization).

2.4.1 Robustezza tramite Selezione Dinamica: RADON

Il metodo **RADON** (*Robust Autoencoder for Unsupervised Anomaly Detection*) [3] affronta direttamente il problema della contaminazione. L'idea chiave è che, anche in un dataset contaminato, gli inliers dovrebbero essere la maggioranza e avere errori di ricostruzione mediamente più bassi degli outliers.

RADON introduce una procedura iterativa che alterna:

1. **Training:** ottimizzazione dell'AE per massimizzare la similarità sugli inliers stimati e minimizzarla sugli outliers stimati.
2. **Proiezione:** aggiornamento dei sottoinsiemi di training (Inliers vs Outliers) tramite *thresholding unimodale* sull'istogramma degli score.

Questo approccio di "filtraggio dinamico" permette di pulire progressivamente il training set senza richiedere etichette manuali.

2.4.2 Migliorare la separabilità: Negative Learning e AE-SAD

Mentre RADON si concentra sulla selezione dei dati, il **Negative Learning** si concentra su *come* trattare gli outlier noti o identificati. Invece di limitarsi a "non addestrare" il modello sugli outlier, il metodo **AE-SAD** [1] propone di sfruttare attivamente questi campioni. Tuttavia, AE-SAD è stato concepito per scenari semi-supervisionati, dove un oracolo fornisce etichette certe per le anomalie. La sua applicazione in contesti non supervisionati (con etichette stimate e rumorose) rimane una sfida aperta.

Il concetto fondamentale è spingere il modello a ricostruire le anomalie verso un **target negativo** (ad esempio, l'inverso dell'input o una trasformazione dissimile), anziché cercare di ricostruire l'input stesso. La loss function diventa ibrida:

$$\mathcal{L} = \mathcal{L}_{\text{rec}}(\text{inliers}) + \lambda \cdot \mathcal{L}_{\text{neg}}(\text{outliers}, \text{target}).$$

Questa strategia forza una divergenza strutturale tra la risposta del modello ai dati normali e a quelli anomali, mitigando drasticamente il rischio di over-generalization.

2.5 Posizionamento del Lavoro

Il presente progetto si colloca all'intersezione di queste due famiglie di metodi. L'obiettivo è combinare la capacità di RADON di identificare *pseudo-outliers* in modo non supervisionato con l'efficacia del Negative Learning di AE-SAD nel distanziare le rappresentazioni. Come verrà dettagliato nella sezione metodologica, questa tesi propone un'estensione di RADON che applica una loss di Negative Learning "feature-aware" sui campioni scartati dalla procedura di selezione dinamica, creando un sistema robusto sia alla contaminazione che alla generalizzazione eccessiva.

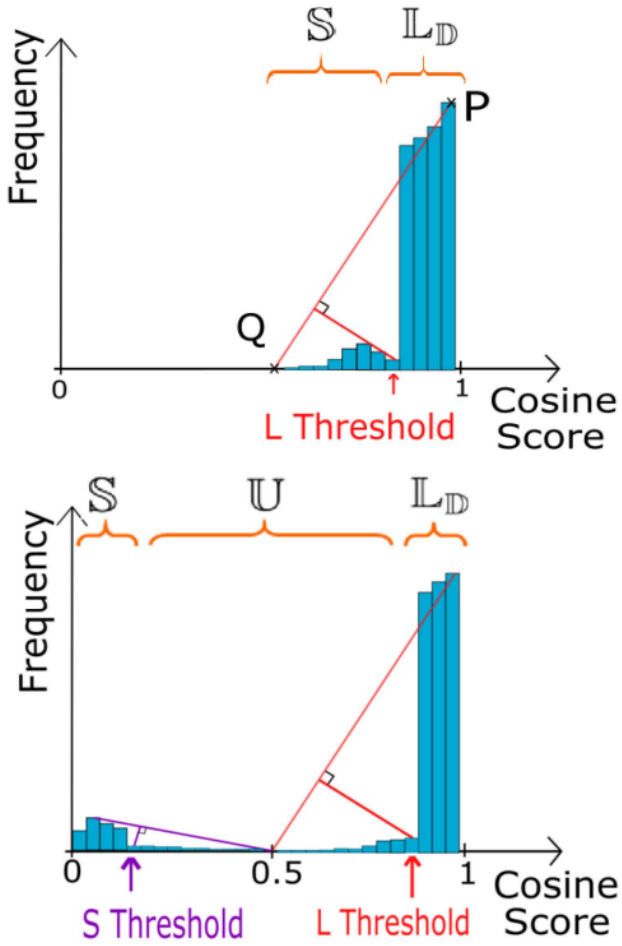


Figure 2.3: Procedura di selezione dinamica in RADON: l'istogramma degli score viene utilizzato per separare inliers e outliers tramite soglie adattive.



Figure 2.4: Concetto di Negative Learning: mentre gli inliers sono ricostruiti fedelmente, gli outliers vengono forzati verso un target distante, aumentando la separabilità.

Chapter 3

Dataset e Analisi Esplorativa

In questo capitolo vengono presentati i dataset utilizzati per la validazione sperimentale: **NSL-KDD** (sicurezza di rete) e **MNIST** (immagini). Coerentemente con la richiesta di un approccio metodologico rigoroso ("spiegazione delle indagini"), per ciascun dataset viene fornita una descrizione dettagliata delle caratteristiche, delle procedure di preprocessing adottate e della strategia di contaminazione utilizzata per simulare scenari reali di anomaly detection non supervisionata.

3.1 NSL-KDD: Network Intrusion Detection

Il dataset NSL-KDD è uno standard di riferimento per la valutazione di sistemi di Intrusion Detection (IDS). Rappresenta una versione raffinata del dataset KDD'99, ripulita da record ridondanti che ne compromettevano la validità statistica. Ogni record rappresenta una connessione di rete descritta da 41 feature originali (tra cui durata, tipo di protocollo, byte trasferiti) e un'etichetta che indica se la connessione è normale o un attacco (e.g., DoS, Probe, R2L, U2R).

3.1.1 Preprocessing e Feature Engineering

Il dataset originale contiene feature eterogenee (categoriche e numeriche). Per rendere i dati compatibili con l'architettura neurale dell'Autoencoder, è stata applicata la seguente pipeline di preprocessing:

1. **One-Hot Encoding:** Le feature categoriche nominali (Protocol Type, Service, Flag) sono state trasformate in vettori binari. Questo processo ha espanso la dimensionalità dello spazio di input da 41 a **122 feature**.

2. **Normalizzazione:** Le feature continue (es. `src_bytes`) sono state normalizzate nell'intervallo $[0, 1]$ tramite Min-Max Scaling, preservando la distribuzione originale ma uniformando le scale.

Un'analisi automatica delle feature post-processing (modulo `TabularFeatureAnalyzer`) ha evidenziato una forte presenza di variabili binarie:

- **Feature Binarie:** 91 su 122 ($\approx 74.5\%$). Queste includono sia le feature categoriche codificate che flag binari nativi.

- **Feature Numeriche:** 31 su 122 ($\approx 25.5\%$).

Questa osservazione è cruciale e giustifica l'adozione del *Feature-Aware Negative Learning* proposto nel Capitolo 4: l'inversione semplice $(1 - x)$ su feature binarie sparse distruggerebbe la semantica (rendendo "attivi" tutti i bit zero), mentre la strategia adottata preserva la natura sparsa dei dati.

3.1.2 Analisi della Distribuzione e Contaminazione

Il dataset originale presenta un notevole sbilanciamento.

- **Inliers (Normali):** 67,343 campioni.
- **Outliers (Attacchi):** 58,630 campioni.

In uno scenario reale di Anomaly Detection non supervisionata, ci si aspetta che le anomalie siano eventi rari. Pertanto, il training set è stato ricampionato per simulare diversi livelli di *contaminazione* (c). Come mostrato in Figura 3.1, per un target $c = 1\%$, il training set finale è composto da:

- **Inliers:** 67,343 (tutti i normali disponibili).
- **Outliers:** ≈ 680 (campionati casualmente dagli attacchi).

Il Test Set **viene mantenuto invariato** (nessun bilanciamento, nessuna manipolazione, nessun filtering). Le metriche (AUROC/AUPRC) sono calcolate su X_{test} con etichette binarie già fornite (0= normal, 1=attack).

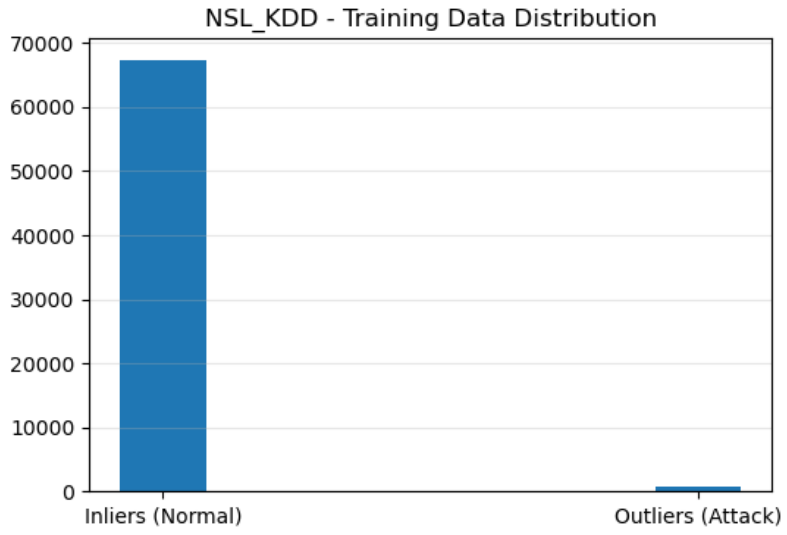


Figure 3.1: Distribuzione delle classi nel training set originale NSL-KDD. Per gli esperimenti, la classe "Outliers" è stata drasticamente sottocampionata (es. all'1%, 5%, 10%) per simulare un reale scenario di anomaly detection.

3.2 MNIST: Rilevazione di Anomalie su Immagini

Sebbene MNIST sia nato per la classificazione di cifre manoscritte, è ampiamente utilizzato come benchmark per l'Anomaly Detection semantica. In questo contesto, una classe (digit) viene eletta come "Normale", mentre le altre vengono trattate come anomalie.

3.2.1 Setup Sperimentale

Per gli esperimenti, si è adottato il seguente protocollo "One-vs-Rest" con due scenari di contaminazione distinti per valutare la robustezza a diverse morfologie di outlier:

- **Classe Normale (Inlier):** Cifra '4'.
- **Scenari di Contaminazione (Outlier):**
  - *Gruppo A (Curve):* Cifre [0, 2, 3].
  - *Gruppo B (Linee/Miste):* Cifre [1, 7, 9].

Ogni immagine 28×28 è stata appiattita in un vettore di dimensione 784 e i valori dei pixel normalizzati in $[0, 1]$. Un'analisi della sparsità mostra che, sebbene i pixel siano tecnicamente continui (livelli di grigio), molti sono "spenti" (background nero). L'analisi automatica ha rilevato 181 feature "binarie" (sempre 0 o 1) e 603 feature continue/variabili.

3.2.2 Strategia di Contaminazione

Il training set non è "pulito", ma è stato costruito iniettando una frazione controllata di cifre anomale (pescate dal Gruppo A o B) tra i campioni normali. Le dimensioni del training set risultante sono:

- **Inliers:** $\approx 4,859$ campioni (tutte le cifre '4' disponibili nel train split).
- **Outliers (Contaminazione):** ≈ 265 campioni.

Questo porta a un tasso di contaminazione del training set pari a circa il **5%**. Il Test Set è stato mantenuto bilanciato o stratificato (es. $\approx 1,000$ normali e ≈ 265 anomalie) per verificare la capacità del modello di generalizzare, rifiutando forme strutturalmente diverse (come lo '0' che è topologicamente un cerchio) pur essendo stato esposto a rumore durante l'addestramento.

3.3 Sintesi delle Indagini

L'analisi preliminare dei due dataset ha guidato le scelte progettuali del metodo proposto:

1. **Natura eterogenea (NSL-KDD):** La presenza massiccia di feature binarie richiede una funzione di inversione selettiva ($F(x)$ feature-aware) per il Negative Learning, per evitare di denaturare l'informazione posizionale dei flag.
2. **Alta dimensionalità e Sparsità:** Sia in NSL-KDD (122 dim) che in MNIST (784 dim), lo spazio è sparso. L'uso della *cosine similarity* (come in RADON) è preferibile all'MSE puro perché si concentra sull'orientamento dei vettori piuttosto che sulla magnitudine, risultando più efficace in spazi ad alta dimensionalità.

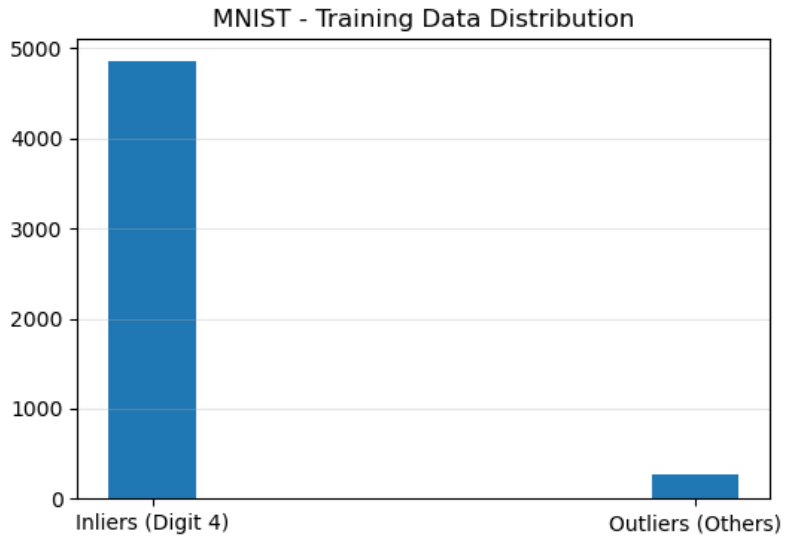


Figure 3.2: Distribuzione delle classi per il setup MNIST (Digit 4 vs Others). Notare l'estremo sbilanciamento introdotto artificialmente nel training set per testare la robustezza di RADON.

3. **Contaminazione Variabile:** La necessità di testare contaminazioni dall'1% al 10% impone l'uso di un metodo con soglie dinamiche (RADON) piuttosto che fisse.

Chapter 4

Metodologia Proposta: RADON con Negative Learning

In questo capitolo viene dettagliata la metodologia sviluppata. L'approccio proposto, denominato **RADON-NL**, combina la robustezza statistica del metodo RADON (Sez. 4.1) con la capacità discriminativa del Negative Learning, adattato per contesti non supervisionati tramite tecniche di stabilizzazione (Sez. 4.2). L'obiettivo è ottenere un modello in grado di auto-pulire il training set dai contaminanti e, simultaneamente, massimizzare la separabilità tra inliers e outliers tramite una funzione di loss ibrida feature-aware.

4.1 Framework di base: RADON

Come architettura fondante è stato scelto RADON (*Robust Autoencoder with Dynamic Outlier filteriNg*). La scelta è motivata dalla necessità di gestire la *contaminazione del training set* in assenza di etichette. Il metodo alterna (i) l'ottimizzazione dei parametri dell'autoencoder e (ii) una **proiezione dinamica** dei campioni in sottoinsiemi *inliers* ($\mathcal{L}$) e *outliers* ($\mathcal{S}$).

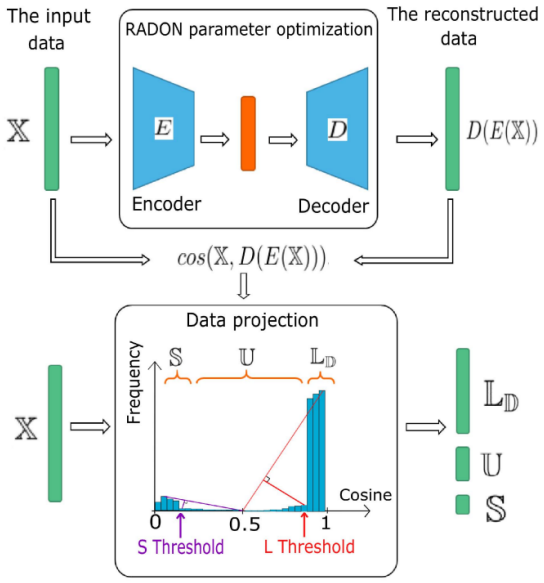


Figure 4.1: Schema del Training in RADON: l'istogramma degli score guida la separazione tra $\mathcal{L}$ e $\mathcal{S}$ [3].

4.1.1 Setup e Similarità di Ricostruzione

Dato il training set $X = \{\mathbf{x}_i\}_{i=1}^{N}$, RADON mantiene una decomposizione dinamica:

$$X = \mathcal{L} \cup \mathcal{S} \cup \mathcal{U},$$

dove $\mathcal{U}$ rappresenta una zona di non-decisione: i campioni borderline non vengono utilizzati per aggiornare i pesi e possono migrare verso $\mathcal{L}$ o $\mathcal{S}$ in proiezioni successive.

In coerenza con l'implementazione, distinguiamo tra: (i) una *similarità interna* utilizzata dal filtro RADON per la proiezione,

$$\tilde{s}(\mathbf{x}) = \cos\big(\mathbf{x}, \hat{\mathbf{x}}\big) = \frac{\langle \mathbf{x}, \hat{\mathbf{x}} \rangle}{\|\mathbf{x}\|_2 \|\hat{\mathbf{x}}\|_2},$$

e (ii) l'*anomaly score* riportato per la valutazione,

$$s(\mathbf{x}) = 1 - \tilde{s}(\mathbf{x}),$$

che è monotono rispetto a $\tilde{s}(\mathbf{x})$ ma più interpretabile in quanto cresce all'aumentare dell'anomalia. Valori elevati di $\tilde{s}(\mathbf{x})$ indicano alta similarità (normalità), valori bassi indicano scarsa ricostruzione (anomalia).

Riepilogo Notazione

Table 4.1: Riepilogo della notazione utilizzata in RADON-NL.

Simbolo	Tipo	Definizione / Ruolo
$\mathbf{x} \in \mathbb{R}^D$	dato	Campione di input (tabulare o immagine appiattita).
$\hat{\mathbf{x}} = f_\theta(\mathbf{x})$	output AE	Ricostruzione prodotta dall'autoencoder con parametri θ.
$\cos(\mathbf{a}, \mathbf{b})$	similarità	$\frac{\langle \mathbf{a}, \mathbf{b} \rangle}{\|\mathbf{a}\|_2 \|\mathbf{b}\|_2}$ (cosine similarity).
$\tilde{s}(\mathbf{x})$	score interno	**Score usato dal filtro RADON in proiezione:** $\tilde{s}(\mathbf{x}) = \cos(\mathbf{x}, \hat{\mathbf{x}})$. Valori alti ⇒ ricostruzione allineata (normalità).
$s(\mathbf{x})$	anomaly score	**Score riportato in valutazione:** $s(\mathbf{x}) = 1 - \tilde{s}(\mathbf{x})$. Valori alti ⇒ anomalia.
$\tau_\mathcal{L}$, $\tau_\mathcal{S}$	soglie	Soglie adattive stimate via thresholding unimodale sull'istogramma di $\tilde{s}(\mathbf{x})$ (con binning di Knuth).
$\mathcal{L}, \mathcal{S}, \mathcal{U}$	insiemi	Partizione dinamica del training set: $\mathcal{L} = \{\mathbf{x} : \tilde{s}(\mathbf{x}) > \tau_\mathcal{L}\}$ (inliers ad alta confidenza), $\mathcal{S} = \{\mathbf{x} : \tilde{s}(\mathbf{x}) < \tau_\mathcal{S}\}$ (outliers pseudo-etichettati), $\mathcal{U} = \{\mathbf{x} : \tau_\mathcal{S} \leq \tilde{s}(\mathbf{x}) \leq \tau_\mathcal{L}\}$ (zona di non-decisione, esclusa dal gradiente).
$F(\mathbf{x})$	trasformazione	Target negativo feature-aware (inversione selettiva): $F(\mathbf{x}) = \mathbf{x} \odot (\mathbf{1} - \mathbf{m}) + (\mathbf{1} - \mathbf{x}) \odot \mathbf{m}$.
$\mathbf{m} \in \{0, 1\}^D$	maschera	Maschera feature-aware: $m_j = 1$ se feature j è numerica continua (invertibile), $m_j = 0$ se binaria/one-hot (preservata).
$w(\mathbf{x})$	peso (CW)	Confidence Weighting per campioni in $\mathcal{S}$ (dominio $\tilde{s}$): $w(\mathbf{x}) \propto \max(0, \tau_\mathcal{S} - \tilde{s}(\mathbf{x}))$, normalizzato nel batch; riduce l'impatto dei borderline.
$\lambda(e)$	scheduling	Ramp-up temporale del contributo negativo: 0 in warmup, poi cresce fino a 1 in E_{ramp} epoche.
λ_{eff}	peso dinamico	Peso effettivo del termine NL dopo scaling per cardinalità (funzione di $\|\mathcal{L}\|/\|\mathcal{S}\|$, stabilizzato via EMA).
γ	iperparametro	Peso della Consistency Loss (regolarizzazione su outliers selezionati).

4.1.2 Funzione Obiettivo Base (Fase Warmup)

Durante la fase iniziale di riscaldamento (*Warmup*), l'autoencoder viene addestrato per massimizzare la similarità sugli inliers stimati e minimizzarla sugli outliers stimati. La loss function base è definita come:

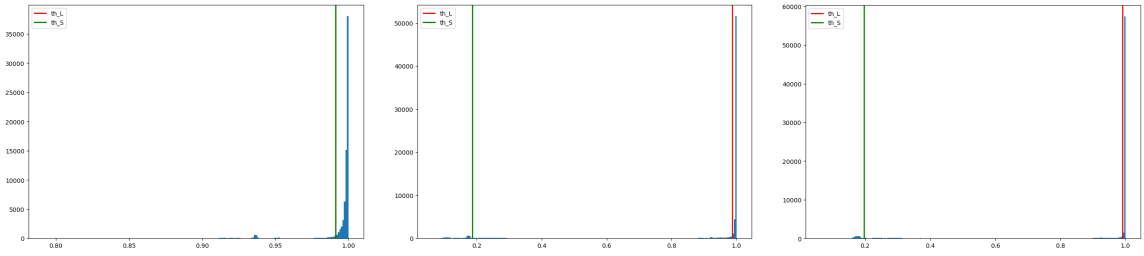
$$\mathcal{L}_{\text{base}} = \underbrace{\mathbb{E}_{\mathbf{l} \sim \mathcal{L}}\left[(1 - \cos(\hat{\mathbf{l}}, \mathbf{l}))^2\right]}_{\text{Inliers: Max Similarità}} + \underbrace{\mathbb{E}_{\mathbf{s} \sim \mathcal{S}}\left[(\cos(\hat{\mathbf{s}}, \mathbf{s}))^2\right]}_{\text{Outliers: Ortogonalità}}.$$

Durante il warm-up, il training segue la loss RADON standard. Nelle prime epoche, prima della prima proiezione, il set $\mathcal{S}$ è inizializzato come insieme nullo e funge da placeholder; dopo la prima proiezione,$\mathcal{S}$ viene popolato con outlier stimati e contribuisce pienamente al termine di ortogonalità.

Pertanto, il warm-up coincide con un regime RADON completo (termini su $\mathcal{L}$ e $\mathcal{S}$), con la sola eccezione delle epoche precedenti alla prima proiezione.

4.1.3 Proiezione Dinamica e Thresholding

Ogni T epoche viene eseguita una fase di *proiezione*. Assumendo che gli inliers costituiscano il picco dominante della distribuzione di $\tilde{s}(\mathbf{x})$, RADON costruisce un istogramma dei valori $\tilde{s}(\mathbf{x}_i)$ sull'intero training set e applica una strategia di *thresholding unimodale* (con binning stimato tramite Knuth) per determinare soglie adattive.



(a) Inizio training (b) Fase intermedia (c) Fine training

Figure 4.2: Evoluzione della distribuzione degli score di similarità $\tilde{s}(x)$ durante il training RADON. Le soglie adattive stimate tramite thresholding unimodale separano progressivamente inliers ($\mathcal{L}$), outliers pseudo-etichettati ($\mathcal{S}$) e la zona di incertezza ($\mathcal{U}$).

Le soglie $\tau_{\mathcal{L}}$ e $\tau_{\mathcal{S}}$ vengono quindi usate per aggiornare i tre insiemi:

$$\mathcal{L} \leftarrow \{\mathbf{x}_i : \tilde{s}(\mathbf{x}_i) > \tau_{\mathcal{L}}\}, \qquad \mathcal{S} \leftarrow \{\mathbf{x}_i : \tilde{s}(\mathbf{x}_i) < \tau_{\mathcal{S}}\},$$

$$\mathcal{U} \leftarrow \{\mathbf{x}_i : \tau_{\mathcal{S}} \leq \tilde{s}(\mathbf{x}_i) \leq \tau_{\mathcal{L}}\}.$$

In altre parole, gli inliers sono campioni con ricostruzione altamente allineata (coseno alto), gli outliers sono campioni con ricostruzione scarsamente allineata (coseno basso), mentre $\mathcal{U}$ implementa una banda di incertezza che riduce l'impatto di pseudo-etichette rumorose.

4.2 Feature-Aware Negative Learning

Per superare i limiti di over-generalization descritti nello Stato dell'Arte, il contributo principale di questo lavoro è l'integrazione del Negative Learning. Invece di limitarsi a degradare la ricostruzione degli outliers (come in RADON base), si forza il modello a ricostruirli verso un *target negativo* $F(\mathbf{x})$.

4.2.1 Trasformazione Feature-Aware $F(\mathbf{x})$

L'applicazione diretta del target negativo $1 - \mathbf{x}$ su dati eterogenei presenta criticità: per feature categoriche codificate One-Hot, l'inversione produrrebbe vettori densi o 'multi-hot' (es. $[0, 1, 0] \rightarrow [1, 0, 1]$) che non risiedono nel sottospazio valido delle feature. Questo disallineamento distribuzionale

può destabilizzare l'autoencoder. Pertanto, definiamo una trasformazione selettiva $F(\mathbf{x})$ tramite una maschera $\mathbf{m}$ (dove $m_j = 1$ se la feature j è numerica continua, 0 se è categorica/binaria):

$$F(\mathbf{x}) = \mathbf{x} \odot (\mathbf{1} - \mathbf{m}) + (\mathbf{1} - \mathbf{x}) \odot \mathbf{m}.$$

In questo modo, il target per la componente categorica rimane l'input stesso (un vettore one-hot valido), e la repulsione è affidata alla minimizzazione della similarità coseno, mentre la componente numerica viene esplicitamente invertita.

4.2.2 Loss di Negative Learning

Sia $\mathbf{s} \in \mathcal{S}$ un campione pseudo-etichettato come outlier dalla procedura di proiezione RADON. Durante la fase di Negative Learning, il modello non è incentivato a ricostruire $\mathbf{s}$ verso l'input originale, ma verso un *target negativo* $F(\mathbf{s})$, ottenuto tramite la trasformazione feature-aware descritta in precedenza.

La loss di Negative Learning a livello di singolo campione è definita come:

$$\mathcal{L}_{NL}(\mathbf{s}) = 1 - \cos\big(f_\theta(\mathbf{s}), F(\mathbf{s})\big),$$

dove $f_\theta(\cdot)$ denota l'output dell'autoencoder e $\cos(\cdot,\cdot)$ la similarità coseno.

Questa formulazione forza il modello a massimizzare la distanza angolare tra la ricostruzione dell'outlier e il suo input originale, aumentando esplicitamente il suo anomaly score. Poiché le pseudo-etichette sugli outlier possono essere rumorose, la loss $\mathcal{L}_{NL}(\mathbf{s})$ viene successivamente aggregata tramite una media pesata basata sulla confidenza del campione, come descritto nella Sezione **??**.

4.2.3 Funzione Obiettivo Totale

La loss complessiva minimizzata durante la fase di Negative Learning combina tre termini:

$$\mathcal{L}_{tot} = \underbrace{\mathcal{L}_{in}(\mathcal{L})}_{\text{Inliers}} + \lambda_{eff} \cdot \underbrace{\mathcal{L}^{cw}_{NL}(\mathcal{S})}_{\text{Outliers}} + \gamma \cdot \underbrace{\mathcal{L}^{cw}_{cons}(\mathcal{S})}_{\text{Consistency}},$$

dove:

- $\mathcal{L}_{in}$ è la loss di ricostruzione standard sugli inliers;
- $\mathcal{L}^{cw}_{NL}$ è la loss negativa feature-aware pesata dalla confidenza;
- $\mathcal{L}^{cw}_{cons}$ è la loss di consistenza;
- λ_{eff} e γ sono i pesi di bilanciamento (descritti nelle sezioni successive).

4.3 Strategie di Stabilizzazione del Training

L'integrazione diretta del Negative Learning in RADON introduce instabilità critiche dovute alla natura intrinsecamente rumorosa delle pseudo-etichette stimate dinamicamente. Questa sezione analizza le problematiche di convergenza riscontrate (Early Divergence, Gradient Shock) e formalizza le soluzioni implementative adottate in RADON-NL.

4.3.1 Pseudo-Etichette e Early Divergence

Nelle prime fasi di addestramento, la rappresentazione latente dell'Autoencoder non è sufficientemente strutturata per separare inliers e outliers in modo affidabile. Di conseguenza, la proiezione $\mathcal{S}$ contiene un numero significativo di falsi positivi (inliers). L'applicazione immediata della loss di Negative Learning su tali campioni induce un effetto distruttivo, forzando il modello a massimizzare l'errore su dati normali. Questo fenomeno, che definiamo *Early Divergence*, porta a una rapida degradazione della rappresentazione appresa.

4.3.2 Protocollo di Warm-up

Per mitigare l'Early Divergence, è stato introdotto un **warm-up strutturato**. Durante le prime E_{wu} epoche, il termine di Negative Learning è disattivato ($\lambda = 0$) e il modello ottimizza la loss **RADON standard**:

$$\mathcal{L}_{\text{base}} = \mathbb{E}_{\mathbf{l}\sim\mathcal{L}}\left[(1 - \cos(\hat{\mathbf{l}}, \mathbf{l}))^2\right] + \mathbb{E}_{\mathbf{s}\sim\mathcal{S}}\left[(\cos(\hat{\mathbf{s}}, \mathbf{s}))^2\right].$$

Quando $\mathcal{S}$ è non vuoto (quindi dopo la prima proiezione), esso viene utilizzato esclusivamente come vincolo di ortogonalità verso l'input originale.

4.3.3 Scheduling Temporale (Ramp-up)

L'attivazione improvvisa della componente negativa all'epoca $E_{wu} + 1$ introdurrebbe una discontinuità significativa nel gradiente.

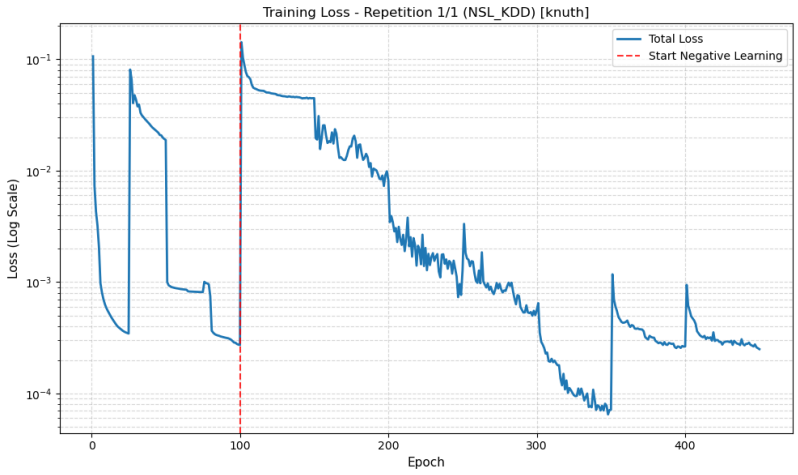


Figure 4.3: Visualizzazione spike appena viene introdotto il Negative learning

Per garantire una transizione fluida, il peso λ segue una rampa lineare:

$$\lambda(e) = \begin{cases} 0 & \text{se } e \leq E_{wu} \\ \min\left(1, \frac{e - E_{wu}}{E_{ramp}}\right) & \text{se } e > E_{wu} \end{cases} \tag{4.1}$$

Questa strategia permette ai gradienti della componente negativa di integrarsi progressivamente con quelli della componente ricostruttiva.

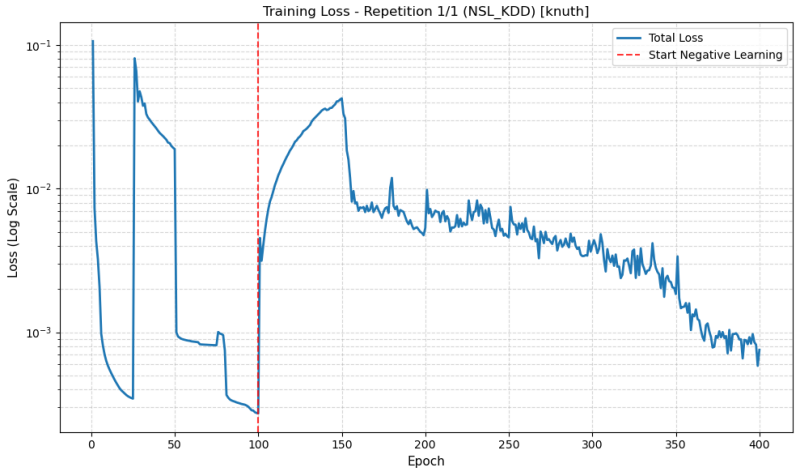


Figure 4.4: Profilo di evoluzione del coefficiente λ durante il training.

4.3.4 Adattamento alla Cardinalità (λ-Scaling)

Oltre alla rampa temporale, l'architettura implementa uno scaling dinamico per compensare il forte sbilanciamento tra classi ($|\mathcal{L}| \gg |\mathcal{S}|$). Per evitare che il gradiente sugli outliers svanisca, il valore base di λ viene modulato in funzione della rarità degli outliers, utilizzando una stima stabilizzata tramite Media Mobile Esponenziale (EMA):

$$r^{(t)} = \frac{|\mathcal{L}^{(t)}|}{\max(1, |\mathcal{S}^{(t)}|)} \tag{4.2}$$

$$\mu_{ratio}^{(t)} = \beta \cdot \mu_{ratio}^{(t-1)} + (1 - \beta) \cdot r^{(t)} \tag{4.3}$$

dove $\beta = 0.9$. Il peso efficace finale è calcolato come:

$$\lambda_{eff} = \lambda_{target} \cdot \sqrt{\mu_{ratio}^{(t)}}.$$

La radice quadrata funge da smorzamento per prevenire instabilità numeriche in casi di estrema scarsità di outliers.

4.3.5 Curriculum Learning (Filtro Quantile)

Poiché l'insieme $\mathcal{S}$ non è uniformemente affidabile, viene applicato un filtro basato sulla confidenza. Durante le prime fasi di Negative Learning, vengono utilizzati per il training solo i campioni nel quantile superiore degli score di anomalia (i più "certi"). La frazione di utilizzo cresce progressivamente da α_{start} a 1.0 (tutto l'insieme $\mathcal{S}$), permettendo al modello di consolidare la separazione sui casi ovvi prima di affrontare quelli ambigui.

4.3.6 Confidence Weighting

Anche con il Curriculum, l'insieme $\mathcal{S}$ contiene campioni borderline. Per ridurre il rischio di *catastrophic forgetting* sugli inliers erroneamente classificati, la loss è calcolata come media pesata:

$$\mathcal{L}_{NL}^{cw} = \frac{\sum_{x \in \mathcal{S}_{batch}} w(x)\, \mathcal{L}_{NL}(x)}{\sum_{x \in \mathcal{S}_{batch}} w(x)}$$

dove il peso $w(x)$ è proporzionale alla distanza dalla soglia sul dominio della similarità:

$$w(x) \propto \max\big(0,\, \tau_{\mathcal{S}} - \tilde{s}(x)\big),$$

così che i campioni con $\tilde{s}(x) \ll \tau_{\mathcal{S}}$ (outliers più certi) ricevano un peso maggiore, mentre i campioni borderline ($\tilde{s}(x) \approx \tau_{\mathcal{S}}$) contribuiscono in modo trascurabile al gradiente.

4.3.7 Consistency Loss Pesata

Infine, per migliorare la robustezza della rappresentazione, è stata integrata una **Consistency Loss**. Per ogni outlier $x \in \mathcal{S}$, viene generata una versione perturbata $x' = x + \epsilon$, dove $\epsilon \sim \mathcal{N}(0, \sigma^2)$ è un rumore gaussiano applicato alle feature continue.

Tuttavia, imporre la coerenza su campioni rumorosi o falsi positivi potrebbe essere controproducente. Per questo motivo, in RADON-NL la Consistency Loss è **modulata dallo stesso peso di confidenza** $w(x)$ utilizzato per il Negative Learning. Si minimizza la distanza Euclidea tra le ricostruzioni dell'input originale e di quello perturbato:

$$\mathcal{L}_{cons}^{cw} = \frac{\sum_{x \in \mathcal{S}_{batch}} w(x) \cdot \|f_\theta(x) - f_\theta(x')\|_2^2}{\sum_{x \in \mathcal{S}_{batch}} w(x)}.$$

Questo accoppiamento garantisce che il vincolo di stabilità locale venga imposto esclusivamente sulle anomalie certe, ignorando i campioni nella zona di incertezza.

4.4 Strategia di Early Stopping Projection-Aware

A differenza degli approcci classici che monitorano la loss ad ogni epoca, è stata sviluppata una strategia specifica per la dinamica iterativa di RADON. La procedura introduce tre accorgimenti fondamentali:

1. **Valutazione Discreta alle Proiezioni:** Il criterio di arresto viene verificato esclusivamente agli step di aggiornamento T, evitando stop prematuri dovuti a fluttuazioni transitorie tipiche delle epoche intermedie.

2. **Criterio di Arresto Formale (L_{in}):** Si monitora il miglioramento della loss di ricostruzione media sugli inliers (L_{in}) tra due proiezioni consecutive k e $k-1$. Definito il delta come:

   $$\Delta^{(k)} = L_{in}^{(k-1)} - L_{in}^{(k)},$$

   il training viene interrotto se il miglioramento è trascurabile, ovvero se $\Delta^{(k)} < \epsilon$ (con $\epsilon = 10^{-6}$) per un numero di proiezioni consecutive pari alla *patience* (nel nostro setup, $P = 3$).

3. **Reset post-Warmup:** La baseline dell'Early Stopping viene resettata al termine del warmup per adattarsi al nuovo regime della loss ibrida, evitando che la loss bassa del warmup (ottenuta senza termine negativo) blocchi il training del Negative Learning.

4.5 Algoritmo Complessivo

L'Algoritmo 1 riassume la logica di training completa.

Algorithm 1: RADON-NL: Training Loop Completo

Input: X, Epoche E, Warmup E_{wu}
Output: Modello f_θ
Init $\mathcal{L} \leftarrow X, \mathcal{S} \leftarrow \varnothing$, maschera $\mathbf{m}$;
for $e = 1$ **to** E **do**
  if $e \leq E_{wu}$ *(Warmup)* **then**
    Ottimizza seguendo RADON standard;
  else `// Negative Learning`
    Calcola λ_{eff} combinando rampa temporale e cardinalità $|\mathcal{L}|/|\mathcal{S}|$; Per ogni batch, calcola target $F(\mathbf{s})$ e pesi w_{conf};
    Ottimizza $\mathcal{L}_{NL}$ (Loss Ibrida + Consistency);
  if $e \bmod T = 0$ *(Proiezione)* **then**
    Calcola $\tilde{s}(x) = \cos(x, \hat{x})$ e stima $\tau_{\mathcal{L}}, \tau_{\mathcal{S}}$ su istogramma;
    Aggiorna $\mathcal{L}$ e $\mathcal{S}$;
    Applica Curriculum (filtro quantile) su $\mathcal{S}$;
    Check Early Stopping su L_{in};

Si noti che, sebbene il warm-up segua formalmente RADON standard, nelle epoche precedenti alla prima proiezione il termine su $\mathcal{S}$ è nullo per costruzione.

Nota sullo Studio di Ablazione

Le strategie di stabilizzazione introdotte in questo capitolo non sono state assunte *a priori* come necessarie, ma sono state motivate da osservazioni empiriche sui fallimenti del training in regime non supervisionato. Al fine di validare quantitativamente il contributo di ciascun meccanismo (warm-up, ramp-up, curriculum, early stopping), è stato condotto uno studio di ablazione sistematico, presentato nel Capitolo 5.

In tale analisi, i moduli vengono attivati progressivamente per isolare il loro impatto sulla stabilità del training e sulle metriche finali di detection, confermando sperimentalmente le motivazioni discusse in questo capitolo.

Chapter 5

Valutazione Sperimentale: Ablation Study e Comparazione con lo Stato dell'Arte

Questo capitolo presenta una valutazione sperimentale approfondita del metodo proposto **RADON-NL**, con l'obiettivo di analizzare sistematicamente il contributo dei singoli componenti introdotti e di confrontare le prestazioni finali con lo stato dell'arte. L'attenzione è rivolta in particolare alla stabilizzazione del *Negative Learning* in regime completamente non supervisionato, dove le etichette sugli outlier sono fornite in modo dinamico e potenzialmente rumoroso dal filtro RADON. Poiché i risultati di RADON e Vanilla AE sono riportati da [3] e non derivano da una replica eseguita nel nostro pipeline, il confronto è da intendersi come riferimento indicativo; l'analisi causale delle componenti del metodo proposto è invece condotta tramite ablation interna.

5.1 Setup Sperimentale e Strategia di Ablation

Setup per riproducibilità

Table 5.1: Dettagli del Setup Sperimentale: Iperparametri, Architettura e Protocollo di Valutazione.

Parametro	**NSL-KDD (Tabulare)**	**MNIST (Immagini)**
	Architettura Autoencoder	
Input Dimension (D)	122 (One-Hot Encoded)	784 (Flattened 28×28)
Hidden Layers	$122 \to 64 \to 32 \to 64 \to 122$	$784 \to 256 \to 128 \to 256 \to 784$
Latent Dimension (Z)	32	128
Funzioni di Attivazione	Hidden: ReLU, Output: Sigmoid	Hidden: ReLU, Output: Sigmoid
	Training e Ottimizzazione	
Optimizer	Adam ($\beta_1 = 0.9, \beta_2 = 0.999$)	Adam ($\beta_1 = 0.9, \beta_2 = 0.999$)
Learning Rate	$1 \cdot 10^{-3}$	$1 \cdot 10^{-3}$
Batch Size	256	256
Total Epochs (E)	450 epoche	200 epoche
Warm-up Epochs (E_{wu})	100 epoche	50 epoche
Projection Freq.(T_{wu})	25 epoche	25 epoche
	RADON-NL Specifics	
Projection Freq. (T_{nl})	50 epoche	50 epoche
λ Ramp-up (E_{ramp})	50 epoche	50 epoche
Thresholding Strategy	Unimodal (Knuth Estimator)	Unimodal (Knuth Estimator)
Early Stopping	Monitoraggio L_{in} @ Proj.	Monitoraggio L_{in} @ Proj.
	Dati e Riproducibilità	
Seed Casuale	Fixed: 42	Fixed: 42
Training Set Split	Inliers + Outliers iniettati	Digit '4' (Normal) + Noise Digits
Contamination Logic	Random Injection ($1\%, 5\%, 10\%$)	Injection ($\approx 5\%$)
Test Set	Originale (Non filtrato)	Stratificato / Bilanciato
	Valutazione	
Anomaly Score	$s(\mathbf{x}) = 1 - \cos(\mathbf{x}, \hat{\mathbf{x}})$	$s(\mathbf{x}) = 1 - \cos(\mathbf{x}, \hat{\mathbf{x}})$
Metriche	AUROC, AUPRC	AUROC, AUPRC

In seguito si riporteranno risultati single-run (seed fisso=42) per comparabilità interna; la varianza non è analizzata e rimane limitazione.

Strategia di Ablation

Lo studio di ablation è stato progettato per valutare l'impatto dei principali moduli di stabilizzazione introdotti in RADON-NL, ovvero:

- **Curriculum Learning** sugli outlier pseudo-etichettati;

- **Ramp-up** del coefficiente di Negative Learning λ;
- **Early Stopping** projection-aware;
- **Confidence Weighting (CW)** basato sulla confidenza dello score.

Ogni componente è stato attivato o disattivato in modo controllato per isolare il suo contributo alla stabilità del training e alle metriche finali di detection. Lo studio è stato condotto su due dataset eterogenei e complementari: **NSL-KDD** (dati tabulari di sicurezza di rete) e **MNIST** (dati image-based), al fine di valutare la robustezza del metodo in contesti strutturalmente differenti.

5.2 Risultati su NSL-KDD: L'impatto delle contaminazioni

La Tabella 5.2 riassume i risultati principali su NSL-KDD al variare del livello di contaminazione del training set, confrontando RADON-NL con le baseline di riferimento riportate in [3].

Table 5.2: NSL-KDD: Ablation Study essenziale.

Cont.	Configurazione	AUROC	AUPRC
1%	Vanilla AE (Baseline)	91.60	91.50
	RADON (Knuth) [3]	94.80	94.40
	RADON-NL (Rampa + ES)	**95.06**	**96.21**
5%	Vanilla AE [3]	89.50	89.70
	RADON (Knuth) [3]	**95.20**	**95.60**
	RADON-NL (Rampa + ES + Curr.)	93.40	93.64
10%	Vanilla AE	88.60	88.90
	RADON (Knuth) [3]	94.40	94.60
	RADON-NL (Base + ES)	**95.80**	**96.43**

Per ciascun livello di contaminazione riportiamo la migliore configurazione RADON-NL osservata in termini di AUPRC. La tabella completa dell'ablation (tutte le configurazioni) è riportata in Appendice A.

5.2.1 Low Contamination (1%)

In presenza di una contaminazione estremamente ridotta, il Negative Learning può essere applicato in maniera aggressiva senza compromettere la stabilità del training. La configurazione *Rampa + Early Stopping* consente a RADON-NL di superare RADON sia in termini di AUROC sia di AUPRC, con un incremento di circa 1.81 punti percentuali in AUPRC. Questo risultato evidenzia come, in scenari low-noise, la spinta antagonista sugli outlier permetta di incrementare la separabilità senza introdurre effetti collaterali.

5.2.2 Standard Contamination (5%)

Al 5% di contaminazione emerge chiaramente la fragilità del Negative Learning non stabilizzato. La versione base di RADON-NL, priva di curriculum (come mostrato nella tabella completa in Appendice A), suggerisce instabilità verso prestazioni prossime a quelle di un Vanilla Autoencoder, dimostrando che l'uso del Negative Learning in regime completamente non supervisionato (pseudo-label) è instabile senza stabilizzazioni.

L'introduzione del **Curriculum Learning**, congiuntamente a rampa e early stopping, consente tuttavia di recuperare circa +3% di AUROC, riportando il modello in un regime competitivo. Sebbene RADON con thresholding di Knuth rimanga superiore, RADON-NL supera nettamente il Vanilla AE, confermando l'efficacia del framework ibrido.

5.2.3 High Contamination (10%)

In regime di alta contaminazione si osserva un fenomeno di *principio di parsimonia*. La configurazione più semplice (*Base + ES*) eguaglia e supera leggermente RADON, mentre l'aggiunta congiunta di rampa e curriculum peggiora le metriche.

Questo risultato suggerisce che, all'aumentare del numero di anomalie, un modello eccessivamente aggressivo risulta controproducente e che la stabilità prevale sulla complessità.

5.3 Explainability (XAI) su NSL-KDD: Attribuzione causale e firma del Negative Learning

Per dati tabulari, l'explainability non può basarsi su mappe spaziali come nel caso image-based. In questo lavoro adottiamo una procedura di XAI *model-consistent* con RADON-NL: le spiegazioni sono espresse come variazioni dell'anomaly score definito dal modello,

$$s(\mathbf{x}) = 1 - \cos(\mathbf{x}, \hat{\mathbf{x}}),$$

e sono costruite tramite interventi controllati sulle feature (ablation) che misurano l'effetto causale sullo score.

5.3.1 Attribuzione per feature categoriche: group ablation verso la modalità dei normali

Le feature categoriche one-hot (e.g., `service_*`, `flag_*`) vengono trattate a gruppi. Per ciascun gruppo g, si costruisce un controfattuale $\mathbf{x}^{(g)}$ imponendo la configurazione più frequente osservata sui normali (*mode* del gruppo). Si misura quindi:

$$\Delta s_g = s(\mathbf{x}^{(g)}) - s(\mathbf{x}).$$

Un valore $\Delta s_g < 0$ indica che "normalizzare" quel gruppo riduce lo score: il gruppo risulta quindi una causa plausibile dell'anomalia.

Nel caso mostrato in Figura 5.1, i gruppi `service` e `flag` risultano fortemente inconsistenti rispetto ai normali (e.g., `service=exec` invece di `http`), con riduzioni di score marcate ($\Delta s \approx -0.26$ sul gruppo `service`). Questa evidenza è coerente con la natura di NSL-KDD, dove molte intrusioni si manifestano come combinazioni atipiche di servizio e flag.

5.3.2 Attribuzione causale per feature numeriche: clip-to-normal (counterfactual)

Per le feature numeriche, si usa un controfattuale "minimamente invasivo": ciascuna feature x_j viene *clippata* nel range tipico dei normali, stimato tramite quantili $[q_{0.05}, q_{0.95}]$ sul training set normale. Si valuta quindi l'impatto sullo score:

$$\Delta s_j = s(\mathbf{x}_{\text{clip}(j)}) - s(\mathbf{x}).$$

Feature con $\Delta s_j \ll 0$ sono interpretate come *driver causali*: riportarle in un range normale riduce lo score in modo significativo. Nel campione anomalo analizzato, indici come `same_srv_rate` e `srv_rerror_rate` risultano fuori-range e con forte impatto ($\Delta s \approx -0.086, -0.046$), indicando una dinamica di connessione non compatibile con la normalità.

5.3.3 Diagnostica della "firma" del Negative Learning

Oltre alle cause, è utile verificare che RADON-NL stia realmente imponendo un comportamento coerente con il Negative Learning. A tal fine si confrontano, per ciascuna feature, due quantità:

$$e_j^+ = |x_j - \hat{x}_j|, \qquad e_j^- = |(1 - x_j) - \hat{x}_j|.$$

Se $e_j^- < e_j^+$, la ricostruzione è più vicina al target negativo rispetto all'input: questo è un indicatore diretto dell'effetto NL (*NL signature*). Nel campione anomalo, le feature più violate mostrano sistematicamente preferenza per il target negativo (10/10 nelle top violated), suggerendo un effetto NL forte e coerente con l'obiettivo di aumentare la separabilità sugli outlier pseudo-etichettati. Al contrario, nei campioni normali tale firma non è osservata (0/10), indicando che l'effetto negativo non "invade" la manifold della normalità.

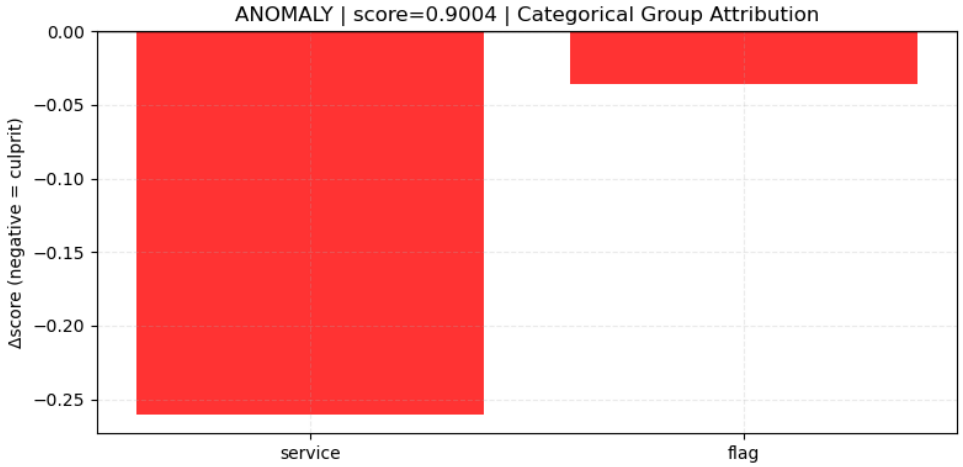


Figure 5.1: NSL-KDD (anomalia): attribuzione per gruppi categorici tramite group ablation verso la modalità dei normali. Valori $\Delta s < 0$ indicano gruppi "colpevoli".

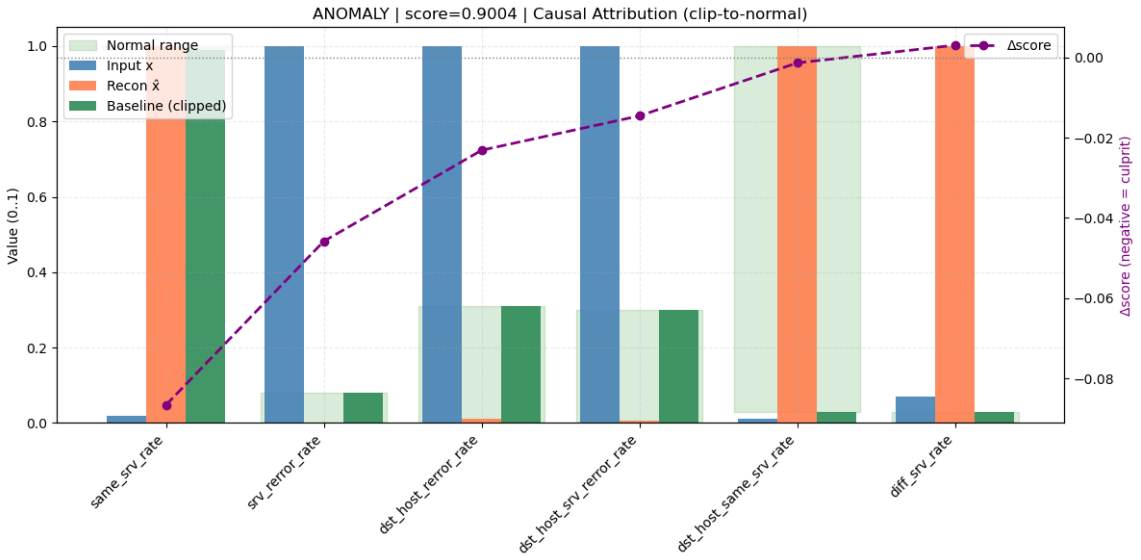


Figure 5.2: NSL-KDD (anomalia): attribuzione causale numerica tramite clip-to-normal. La banda verde rappresenta il range tipico dei normali; la curva Δs identifica le feature che, se normalizzate, riducono maggiormente lo score.

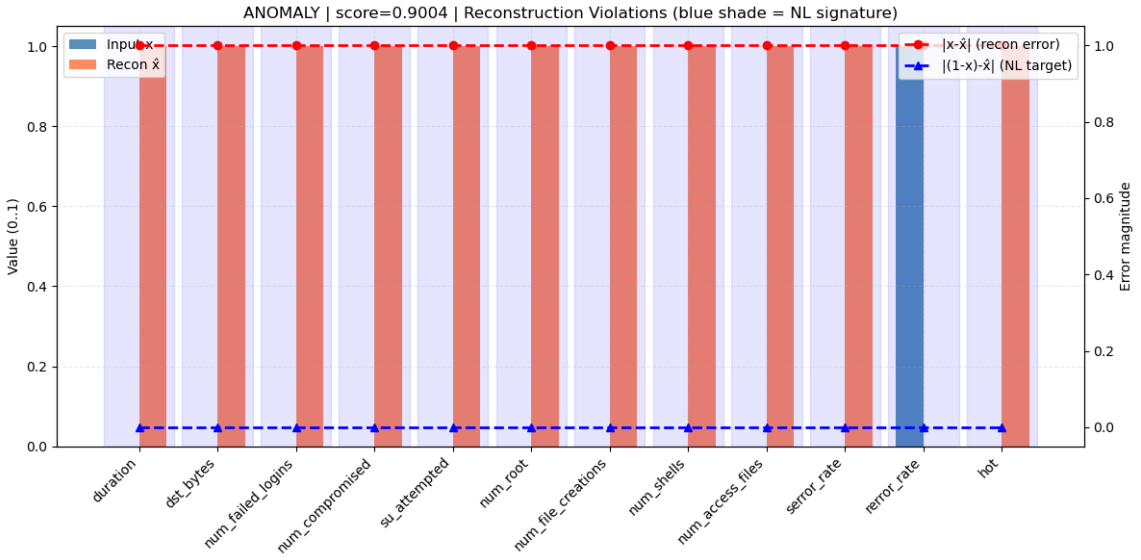


Figure 5.3: NSL-KDD: diagnostica della firma del Negative Learning su un campione anomalo. Le regioni evidenziate indicano feature con $e^- < e^+$, quindi ricostruzioni più vicine al target negativo.

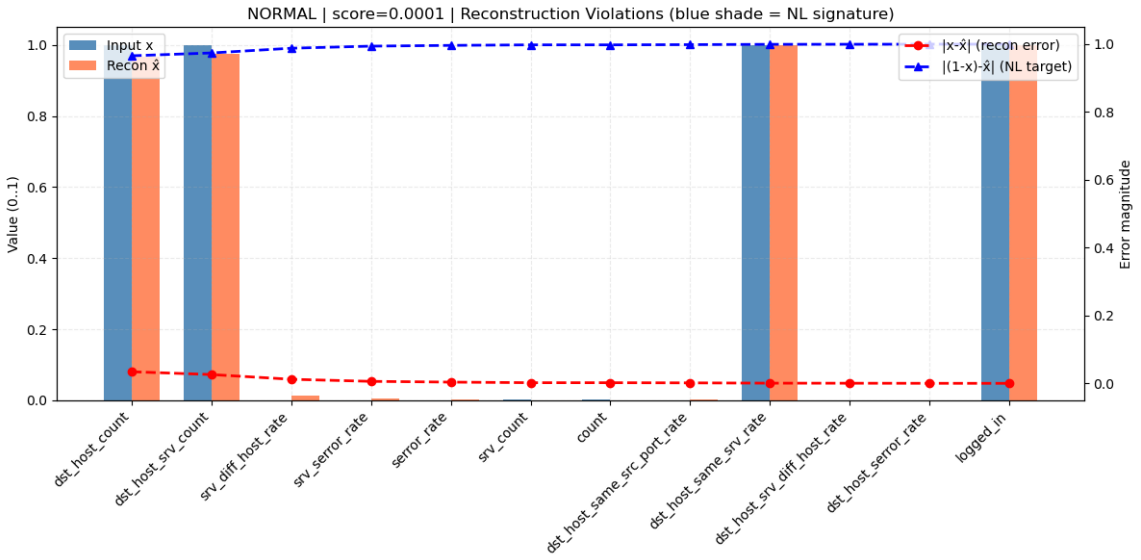


Figure 5.4: NSL-KDD: campione normale. La firma del Negative Learning è assente (nessuna preferenza sistematica per il target negativo), coerentemente con la preservazione della ricostruzione sugli inliers.

5.4 Risultati su MNIST: Geometria e Stabilità

Lo studio su MNIST analizza l'impatto della geometria degli outlier, distinguendo tra uno scenario *Easy* e uno *Hard*.

Nota sulle Metriche di Loss

Oltre alle metriche di detection (AUROC, AUPRC), per gli esperimenti su MNIST viene riportata la *loss finale* come indicatore di stabilità del training. In particolare, con il termine *loss finale* si intende la perdita media di ricostruzione sugli inliers:

$$L_{in} = \mathbb{E}_{\mathbf{l}\sim\mathcal{L}}\left[(1 - \cos(f_\theta(\mathbf{l}), \mathbf{l}))^2\right],$$

valutata sull'ultimo modello selezionato tramite early stopping.

Questa scelta è motivata dal fatto che L_{in} è la metrica monitorata dal criterio di arresto e riflette direttamente la qualità della rappresentazione della normalità, indipendentemente dai pesi dinamici introdotti dal Negative Learning.

5.4.1 Easy Group: Geometria Distinta

Table 5.3: MNIST Easy Group (Outlier: 0,2,3).

Metodo	**AUROC**	**AUPRC**	**Loss Finale**
RADON (avg) [3]	97.00	88.88	N/A
RADON-NL + ES + Curriculum	**97.35**	**91.72**	**0.0047**
RADON-NL + ES	97.06	89.70	0.0191

La drastica riduzione della loss finale (da 0.0191 a 0.0047) costituisce una prova quantitativa dell'efficacia del Curriculum Learning, che previene la divergenza precoce del Negative Learning.

5.4.2 Hard Group: Ambiguità Morfologica

Table 5.4: MNIST Hard Group (Outlier: 1,7,9).

Metodo	**AUROC**	**AUPRC**
RADON (Base)	87.20	70.56
RADON-NL + ES + CW	**90.21**	**74.18**

Questo scenario rappresenta il caso peggiore anche per RADON [3], che identifica le cifre 1 e 7 come principali falsi negativi. L'incremento di oltre +3% ottenuto tramite **Confidence Weighting** evidenzia come una pesatura soft del segnale negativo sia cruciale quando l'ambiguità morfologica rende dannosa una soglia rigida.

5.4.3 Analisi XAI: Interpretabilità delle Ricostruzioni

Uno dei vantaggi intrinseci degli approcci basati su Autoencoder è la loro *interpretabilità by design*. A differenza di modelli puramente discriminativi o one-class nello spazio latente, un Autoencoder fornisce una ricostruzione esplicita dell'input, permettendo di analizzare *dove* e *quanto* il modello fallisce nel rappresentare un campione.

Nel contesto di RADON-NL, l'anomaly score è direttamente legato alla dissimilarità tra input e ricostruzione. Di conseguenza, la mappa dell'errore di ricostruzione costituisce una spiegazione locale immediata della decisione del modello.

La Figura 5.5 mostra esempi rappresentativi di campioni normali (inliers) e anomali (outliers) dal test set MNIST, visualizzando:

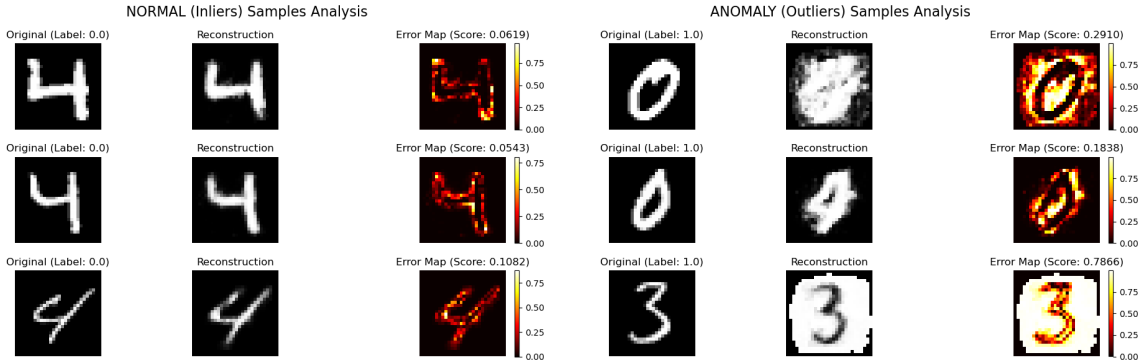
- l'immagine originale
- la ricostruzione prodotta dall'autoencoder
- la mappa dell'errore assoluto.

Per i campioni normali (digit '4'), il modello ricostruisce fedelmente la struttura principale della cifra, con errori localizzati prevalentemente lungo i bordi o in regioni a bassa intensità. Al

contrario, per i campioni anomali, la ricostruzione risulta sfocata, deformata o strutturalmente incoerente, producendo mappe di errore diffuse e di maggiore intensità.

Questo comportamento conferma visivamente il meccanismo alla base del Negative Learning: il modello è incentivato non solo a ricostruire bene la normalità, ma a *fallire attivamente* sulle anomalie, amplificando la separazione nello spazio degli score.

L'analisi XAI supporta quindi quantitativamente e qualitativamente i risultati di detection, mostrando che le decisioni del modello sono coerenti, interpretabili e allineate con la semantica del dato.



(a) Campioni normali (Inliers)

(b) Campioni anomali (Outliers)

Figure 5.5: Analisi XAI su MNIST: confronto tra immagini originali, ricostruzioni e mappe di errore. Gli outliers mostrano errori strutturali più estesi, coerenti con anomaly score elevati.

5.5 Il ruolo delle componenti

Lo studio di ablation consente di trarre tendenze coerenti sul ruolo dei singoli componenti:

- **Curriculum Learning**: tendenzialmente porta miglioramenti alla stabilità del Negative Learning non supervisionato.
- **Early Stopping**: fondamentale per l'efficienza computazionale e per prevenire overfitting sugli outlier rumorosi.
- **Ramp-up**: efficace solo in scenari a bassa contaminazione.
- **Confidence Weighting**: su NSL-KDD non osserviamo benefici consistenti: CW tende a ridurre AUROC e non produce un incremento stabile di AUPRC (Tab. A.1). Si noti che è particolarmente efficace in presenza di ambiguità morfologica nelle immagini.

Nel complesso, RADON-NL si dimostra superiore a un Vanilla Autoencoder e competitivo, allo stato dell'arte RADON [3], il quale è migliorato in alcuni regimi, ma non viene dominato sistematicamnete. Ciò conferma che il Negative Learning di AE-SAD [1] può essere adattato con successo a un contesto completamente non supervisionato, purché opportunamente stabilizzato.

Appendix A

Tabella completa Ablation NSLKDD

Table A.1: NSL-KDD: Ablation Study completo al variare della contaminazione. (Valori in %)

Cont.	Configurazione	AUROC	AUPRC
1%	Vanilla AE (Baseline)	91.60	91.50
	RADON (Knuth) [3]	94.80	94.40
	RADON-NL (Base + ES)	93.63	93.88
	RADON-NL (Base + ES + CW)	92.40	93.90
	RADON-NL (Rampa + ES)	**95.06**	**96.21**
	RADON-NL (Rampa + ES + Curr.)	93.40	95.00
	RADON-NL (Rampa + ES + Curr.+ CW)	92.16	93.42
5%	Vanilla AE [3]	89.50	89.70
	RADON (Knuth) [3]	**95.20**	**95.60**
	RADON-NL (Base + ES)	90.63	89.28
	RADON-NL (Base + ES + CW)	90.65	88.50
	RADON-NL (Rampa + ES)	90.92	91.91
	RADON-NL (Base + ES + Curr.)	93.46	91.64
	RADON-NL (Rampa + ES + Curr.)	93.40	93.64
	RADON-NL (Rampa + ES + CW)	92.75	91.74
	RADON-NL (Rampa + ES + Curr.+ CW)	92.75	91.74
10%	Vanilla AE	88.60	88.90
	RADON (Knuth) [3]	94.40	94.60
	RADON-NL (Base + ES)	**95.80**	**96.43**
	RADON-NL (Base + ES + Curriculum)	94.03	95.00
	RADON-NL (Base + ES + CW)	93.45	94.60
	RADON-NL (Rampa + ES)	92.00	92.40
	RADON-NL (Rampa + ES + Curr.)	91.34	92.93
	RADON-NL (Rampa + ES + Curr.+ CW)	92.31	93.50

Bibliography

[1] Fabrizio Angiulli, Fabio Fassetti, and Luigi Palopoli. Reconstruction error-based anomaly detection with few outlying examples. *Machine Learning*, 112(6):2301–2335, 2023.

[2] Raghavendra Chalapathy and Sanjay Chawla. Deep learning for anomaly detection: A survey. *ACM Computing Surveys*, 54(2):1–38, 2019.

[3] Naji Najari, Boulbaba Ben Amor, and Zied Elouedi. Robust autoencoders for unsupervised anomaly detection. In *International Conference on Machine Learning and Applications (ICMLA)*, pages 253–260. IEEE, 2021.

[4] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, and Klaus-Robert Müller. Deep semi-supervised anomaly detection. *arXiv preprint arXiv:1906.02694*, 2020.

[5] Lukas Ruff, Robert A. Vandermeulen, Nico Goernitz, Lucas Deecke, Shoaib A. Siddiqui, Alexander Binder, Klaus-Robert Müller, and Marius Kloft. Deep one-class classification. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, volume 80 of *Proceedings of Machine Learning Research*, pages 4393–4402, 2018.